**212-Корепин-эссе-DBSCAN**

## Что это

DBSCAN — алгоритм кластеризации по плотности. Его предложили М. Эстер, Х.-П. Кригель, Й. Зандер и С. Сюй в 1996 году. Название расшифровывается как Density-Based Spatial Clustering of Applications with Noise: кластеризация по плотности с учётом шума. Кластер в DBSCAN — это область, где точки лежат густо. Редкие точки между такими областями алгоритм объявляет шумом и в кластеры не берёт.

## Параметры и типы точек

У алгоритма два параметра: радиус ε и число MinPts. Соседи точки — все точки ближе ε. У нас ε — это порог волны, а MinPts преподаватель обозначил K. Дальше каждая точка получает один из трёх типов.

- **Базовая** точка: у неё не меньше K соседей. Она сидит внутри плотного облака.
- **Периферийная** точка: соседей меньше K, но среди них есть базовая. Это край облака.
- **Шум**: остальные точки. Рядом с ними нет ни одной базовой.

Кластер растёт как пожар, но огонь передают только базовые точки. Периферийная точка загорается от базовой соседки и дальше огонь не несёт.

## Связь с волной

Если посмотреть на DBSCAN как на граф, получается то, что мы уже умеем. Матрица D по порогу ε даёт двоичную матрицу B, это тот же граф, что и для волны. Число единиц в строке B — степень вершины, то есть число соседей. Фильтр DBSCAN оставляет в графе базовые и периферийные точки (граф B*), а шум выкидывает. По B* запускается обычная волна. Значит, DBSCAN — это волна, перед которой граф очистили от шума.

## Почему DBSCAN убирает муравьиную тропу

Муравьиная тропа — цепочка точек между двумя облаками, где соседние точки ближе порога. Для волны и для дерева такая тропа — обычный путь в графе, поэтому два облака сливаются в один кластер. У точки на

тропе всего два соседа: впереди и сзади. При $K \geq 3$ она не может быть базовой. Огонь по тропе никто не передаёт: точки тропы рядом с облаком станут периферийными, а точки в середине тропы — шумом. Облака остаются раздельными.

В графе B* рёбра оставляем, только если хотя бы один конец базовый. Ребро между двумя периферийными точками соседних облаков тоже могло бы их склеить, а так мост не появится.

**Пример на Python**

Два облака по 150 точек и тропа из 17 точек с шагом 0,3. Параметры: $\varepsilon = 0{,}45$, MinPts = 4.

```
# Группа 212, Корепин Матвей
# Пример DBSCAN на Python: два облака и муравьиная тропа между ними.
import numpy as np
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt

rng = np.random.default_rng(212)
a = rng.normal([-3, 0], 0.7, size=(150, 2))           # облако 1
b = rng.normal([3, 0], 0.7, size=(150, 2))            # облако 2
tx = np.arange(-2.5, 2.6, 0.3)
t = np.column_stack([tx, np.zeros(len(tx))])           # тропа
points = np.vstack([a, b, t])

eps, min_pts = 0.45, 4

# Соседи: точки ближе eps (сама точка не считается).
d = np.sqrt(((points[:, None, :] - points[None, :, :]) ** 2).sum(axis=2))
neighbours = [np.where((d[i] < eps) & (np.arange(len(points)) != i))[0]
              for i in range(len(points))]

# Базовые точки: не меньше min_pts соседей.
core = np.array([len(nb) >= min_pts for nb in neighbours])

# Кластеры растут только от базовых точек.
label = np.full(len(points), -1)
cluster = 0
for i in range(len(points)):
    if not core[i] or label[i] != -1:
        continue
    label[i] = cluster
    queue = [i]
    while queue:
        p = queue.pop()
        for q in neighbours[p]:
            if label[q] == -1:
                label[q] = cluster
                if core[q]:          # дальше идём только от базовых
                    queue.append(q)
    cluster += 1
```

```
print("кластеров:", cluster, "шум:", int((label == -1).sum()))

plt.figure(figsize=(7, 3.6))
colors = ["#e6194b", "#4363d8"]
for c in range(cluster):
    m = label == c
    plt.scatter(points[m, 0], points[m, 1], s=10, c=colors[c % 2])
m = label == -1
plt.scatter(points[m, 0], points[m, 1], s=18, c="#999999", marker="x",
label="шум")
plt.title("DBSCAN: eps = 0.45, MinPts = 4 — тропа стала шумом")
plt.legend(loc="upper right")
plt.axis("equal")
plt.tight_layout()
plt.savefig("dbscan_python.png", dpi=150)
```

Программа печатает «кластеров: 2 шум: 16». Тропа стала шумом, облака не склеились (рисунок 1).

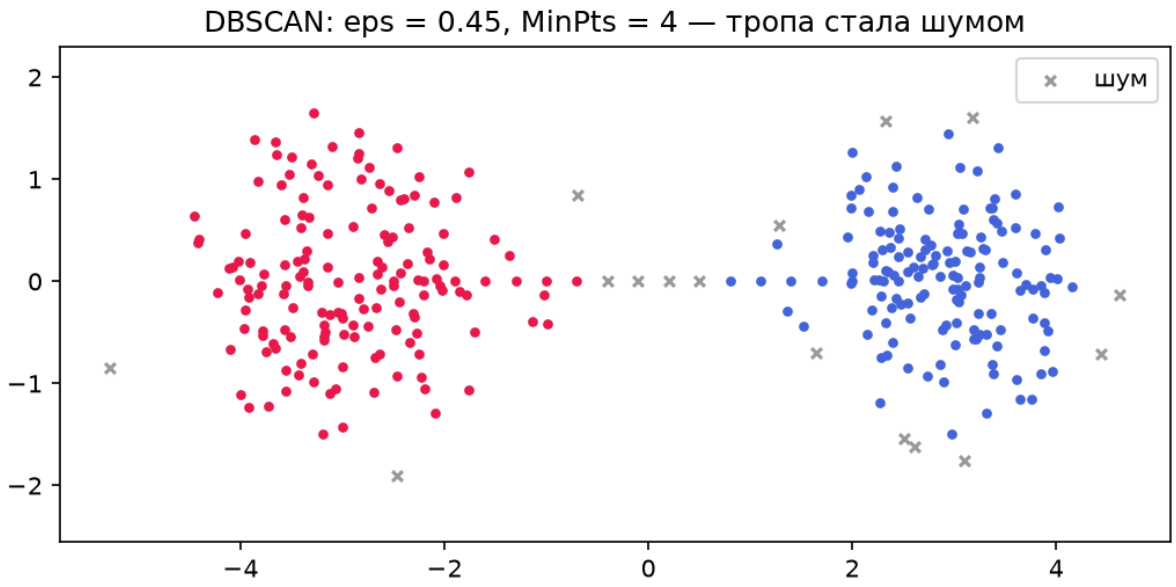



Рисунок 1. Результат примера на Python: серые крестики — шум

**Как это работает в моей программе на C++**

Программа строит пять облаков и две тропы: между облаками внизу слева и в центре и между двумя верхними облаками. Обычная волна по графу B с порогом 0,4 находит только 3 кластера, тропы склеили облака попарно. После фильтра DBSCAN при любом K от 3 до 6 кластеров снова 5.

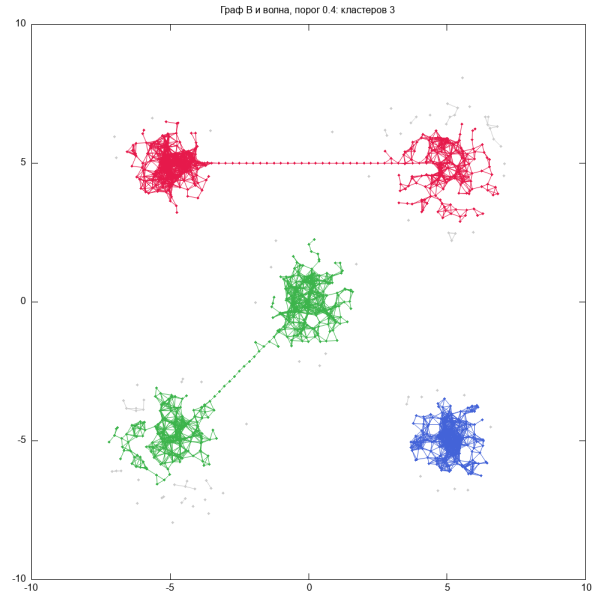



Рисунок 2. Граф B и обычная волна: 3 кластера

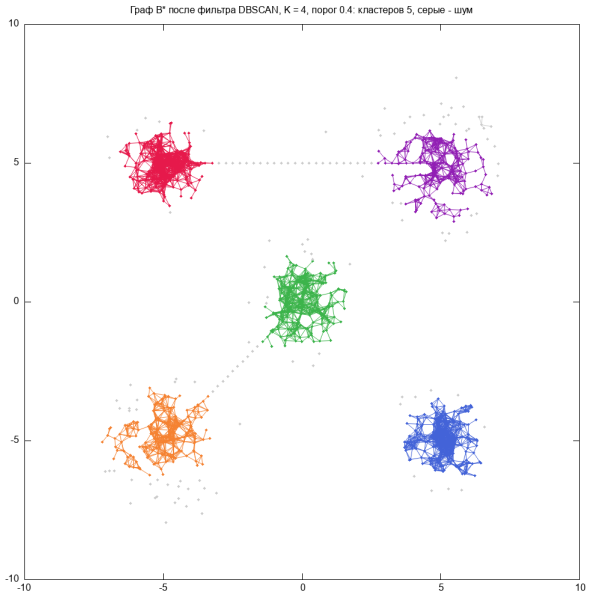



Рисунок 3. Граф B* после фильтра, K = 4: 5 кластеров

**Плюсы и минусы**

- Не нужно задавать число кластеров, кластеры могут быть любой формы.
- Шум и тропы отсекаются сами.
- Если облака разной плотности, одной пары (ε, K) на все не хватит: редкое облако целиком уйдёт в шум.
- Нужно подбирать ε и K. Помогает гистограмма длин рёбер покрывающего дерева: порог ставят за провалом между короткими и длинными рёбрами.

Источник: Ester M., Kriegel H.-P., Sander J., Xu X. A density-based algorithm for discovering clusters in large spatial databases with noise // Proceedings of KDD-96. 1996. P. 226–231.