212-Корепин-эссе-Иерархический кластерный анализ

Идея

Обычные алгоритмы, например k-means, дают одно разбиение точек на группы. Иерархический кластерный анализ строит сразу целую лестницу разбиений, вложенных друг в друга: от «каждая точка — отдельный кластер» до «все точки в одном кластере». Эту лестницу рисуют деревом, которое называется дендрограммой. Подробно метод разобран в книге М. Жамбю «Иерархический кластер-анализ и соответствия».

Два направления

- **Агломеративный** (снизу вверх): сначала каждая точка — отдельная группа. На каждом шаге сливаем две самые близкие группы. Через n − 1 шаг остаётся одна группа.
- **Дивизивный** (сверху вниз): начинаем с одной группы и на каждом шаге делим её на две.

Чаще пользуются агломеративным: он проще, и каждый шаг понятен.

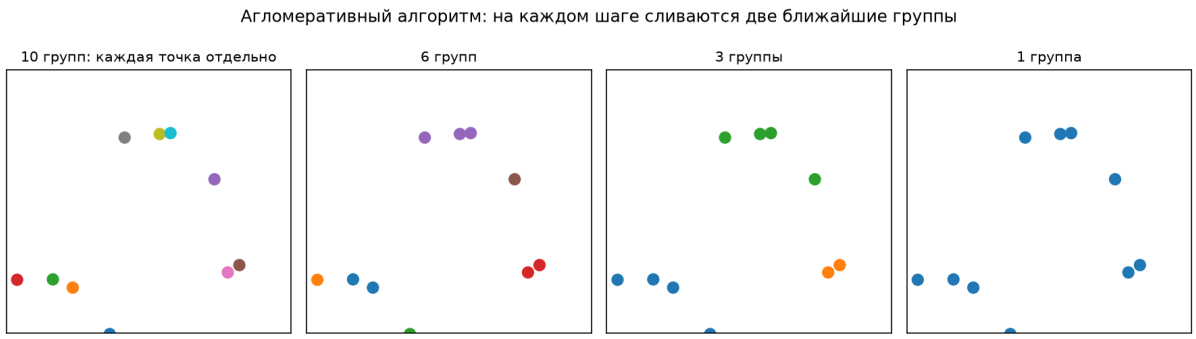


Рисунок 1. Агломеративный алгоритм: десять точек сливаются в одну группу

Расстояние между группами

Расстояние между точками берём из матрицы D. А как мерить расстояние между двумя группами? От ответа зависит результат.

- **Одиночная связь** (ближайший сосед): расстояние между двумя самыми близкими точками групп.
- **Полная связь** (дальний сосед): расстояние между двумя самыми далёкими точками.
- **Средняя связь**: среднее всех расстояний между точками двух групп.

- **Метод Уорда**: сливаем те группы, при слиянии которых меньше всего растёт разброс точек вокруг центров.

Все эти правила укладываются в одну формулу Ланса — Уильямса. После слияния групп A и B расстояние от новой группы до любой группы C считается через d(A,C), d(B,C) и d(A,B) с разными коэффициентами. Поэтому матрицу расстояний не нужно пересчитывать заново: достаточно обновить одну строку.

Дендрограмма и срез

По вертикали дендрограммы откладывают расстояние, на котором слились группы. Чтобы получить нужное число кластеров, дендрограмму режут горизонтальной линией. Сколько ветвей она пересекла, столько и кластеров. Длинные вертикальные ветви — признак хорошо разделённых групп: их долго не удаётся слить.

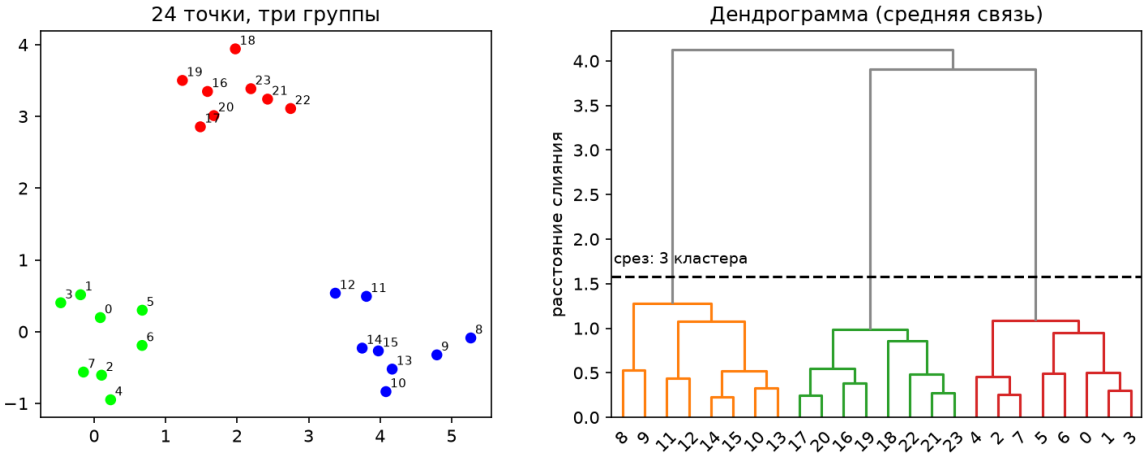


Рисунок 2. 24 точки и их дендрограмма. Срез на высоте 1,6 даёт три кластера

Связь с деревом и волной

Иерархия по одиночной связи — это минимальное покрывающее дерево. Краскал добавляет рёбра от коротких к длинным, и каждое ребро сливает две группы, как в агломеративном алгоритме. Срез дендрограммы на высоте T даёт те же группы, что и дерево, из которого выкинули рёбра длиннее T. Это же связные компоненты графа с порогом T, их находит волна. В программе с деревом я проверил это тестом: дерево, разрезанное по порогу 0,4, даёт столько же компонент, сколько волна с тем же порогом.

Эффект цепочки

У одиночной связи есть та же беда, что у волны: муравьиная тропа. Если между облаками цепочка точек, одиночная связь сольёт облака раньше, чем отделит лишнюю точку. Полная связь цепочек не боится: она смотрит на самые далёкие точки групп, и вытянутая группа для неё «большая».

Два кластера при разных правилах связи: одиночная склеивает облака по цепочке

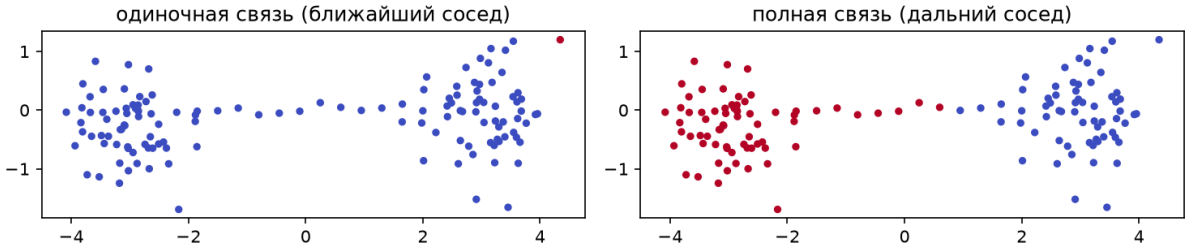


Рисунок 3. Те же точки, два кластера: одиночная связь склеила облака по тропе, полная — разделила

Сколько это стоит

Нужна матрица расстояний: n^2 чисел памяти. На каждом из $n - 1$ шагов ищется пара ближайших групп. Простая реализация работает за n^3 операций, с хранением минимумов по строкам — за n^2. Для 20 000 точек это уже тяжело, поэтому на больших данных сначала сжимают точки, например формальным элементом, и строят иерархию по центрам.

Плюсы и минусы

- Не нужно заранее знать число кластеров: его выбирают по дендрограмме.
- Видна вся структура данных: какие группы близки, какие далеки.
- Слияние нельзя отменить: ошибка на раннем шаге остаётся до конца.
- Много памяти и времени на больших данных.

Источник: Жамбю М. Иерархический кластер-анализ и соответствия. М.: Финансы и статистика, 1988.