212-Корепин-эссе-Формальный элемент (ФОРЭЛ)

Откуда алгоритм

ФОРЭЛ расшифровывается как «формальный элемент». Алгоритм придумали в 1960-х годах в Институте математики Сибирского отделения Академии наук, в группе Н. Г. Загоруйко в Новосибирске. Его считают одним из первых российских алгоритмов кластеризации. Он берёт от k-means пересчёт центра тяжести, а от иерархического анализа — уровни: сначала мелкие сгустки, потом из них крупные.

Идея

Возьмём круг радиуса R и положим его на облако точек. Посчитаем центр тяжести точек, которые попали в круг, и передвинем круг туда. Если внутри круга точки распределены неравномерно, центр тяжести смещён в сторону, где их больше. Поэтому круг шаг за шагом ползёт к самому плотному месту и останавливается на вершине сгустка. Точки под остановившимся кругом и есть кластер, или «формальный элемент».

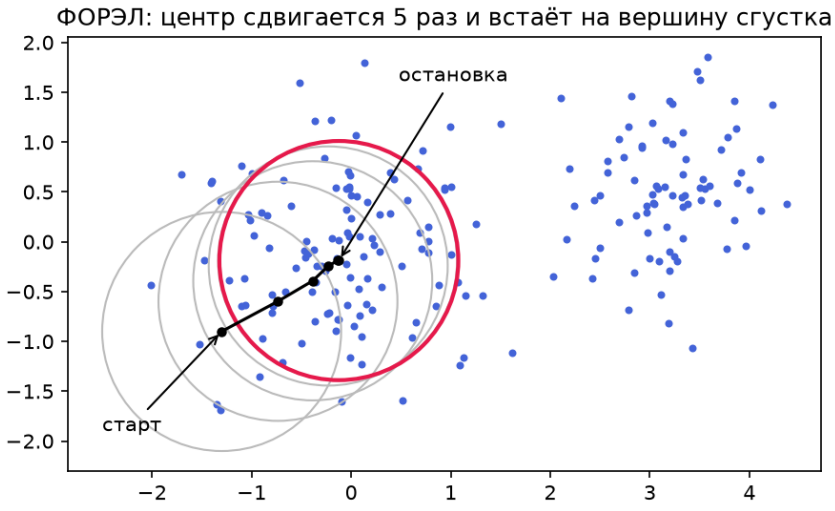


Рисунок 1. Круг радиуса R ползёт к вершине сгустка. Серые круги — промежуточные положения, красный — остановка.

Шаги алгоритма

1. Берём любую ещё не собранную точку и ставим в неё центр.

2. Собираем все несобранные точки на расстоянии не больше R от центра.
3. Считаем их центр тяжести и переносим туда центр.
4. Повторяем шаги 2–3, пока центр сдвигается больше чем на ε.
5. Точки под кругом вырезаем: это один кластер. Его центр тяжести запоминаем.
6. Возвращаемся к шагу 1, пока точки не кончатся.

Число кластеров заранее задавать не нужно, в отличие от k-means. Его определяет радиус: чем меньше R, тем больше мелких сгустков.

Второй уровень

После первого уровня у нас вместо тысяч точек остаются сотни центров тяжести. У каждого центра есть вес — сколько исходных точек за ним стоит. Теперь радиус увеличиваем в 2–3 раза и запускаем тот же алгоритм уже по центрам. Центр тяжести считаем с весами, чтобы центр, за которым 30 точек, тянул сильнее центра с одной точкой. Так получается иерархия: точки → сгустки → крупные сгустки. Повторять можно сколько угодно раз, пока мы остановились на двух уровнях.

Главная польза второго уровня в том, что точек для дальнейшей работы становится в десятки раз меньше. По центрам можно запустить волну или DBSCAN: матрица расстояний для 250 центров занимает 0,1 МБ, а для 10 000 точек — около 200 МБ.

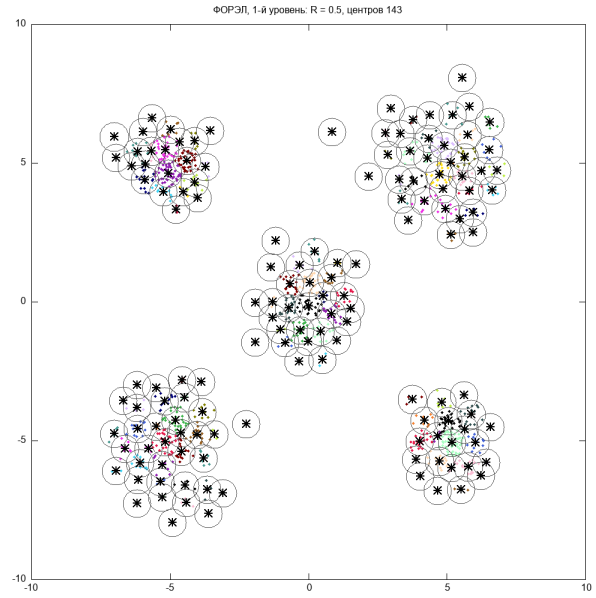


Рисунок 2. Первый уровень, R = 0,5: 143 центра

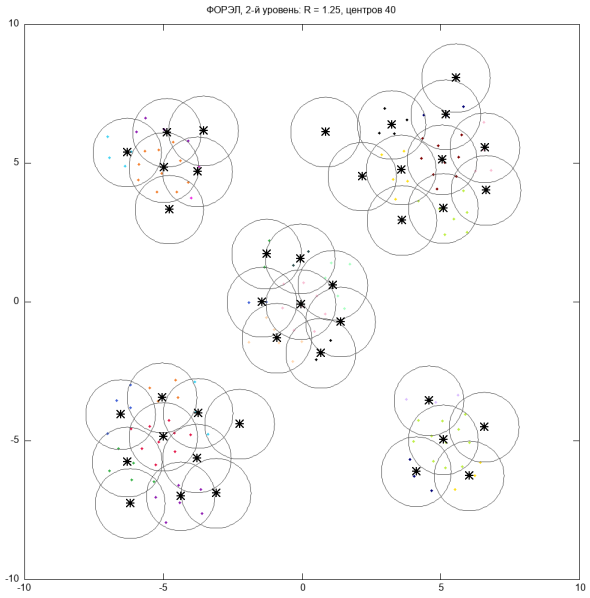


Рисунок 3. Второй уровень, R = 1,25: 40 центров

Что получилось в моей программе

Программа строит пять гауссовых облаков, проходит два уровня ФОРЭЛ и запускает волну по центрам первого уровня с порогом 2R. Параметры R, ε и множитель второго уровня берутся из файла config.txt.

Точек	R	Центров 1-го уровня	Центров 2-го уровня	Время 1-го уровня, мс
1000	0,5	143	40	0,3
5000	0,5	204	53	5,2
10000	0,5	248	61	14,8
20000	0,5	277	64	31,2

На 20 000 точках первый уровень оставляет 277 центров, то есть точек становится в 72 раза меньше. Волна по этим центрам находит все пять облаков (рисунок 4).

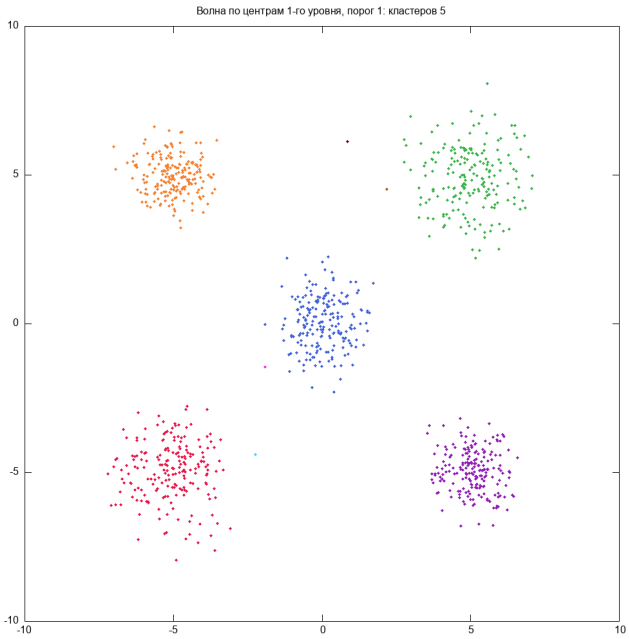


Рисунок 4. Волна по центрам первого уровня: пять кластеров

Радиус нельзя брать слишком большим. На 10 000 точках при R = 1 волна по центрам находит только 3 кластера: на краях облаков появляются редкие центры, и они цепочкой соединяют соседние облака. При R = 0,5 таких мостов нет.

Плюсы и минусы

- Не нужно знать число кластеров заранее.
- Сразу даёт центры кластеров и сжимает данные.
- Результат зависит от порядка точек: с какой точки начали, там и первый круг.
- Круг одного радиуса плохо подходит, если облака разной ширины.

Источники: лекция 31.10.2026; Загоруйко Н. Г. Прикладные методы анализа данных и знаний. Новосибирск: Изд-во Ин-та математики, 1999.